



Estatística Computacional com R (PPGBC/UFPA e PPGCTIF/UFOPA)



🌿 Análise Exploratória de Dados no R 🌿

(Pacotes: Tidyverse, summarytools e DataExplorer)



Prof. Dr. Deivison Venicio Souza

Universidade Federal do Pará (UFPA)

Faculdade de Engenharia Florestal

Laboratório de Manejo Florestal, Tecnologias e Comunidades Amazônicas

E-mail: deivisonvs@ufpa.br

1ª versão: 14/outubro/2022

(Atualizado em: 02/julho/2026)



PPGCTIF



Objetivos



Ao final desta aula ([Análise Exploratória de Dados](#)), espera-se que o discente seja capaz de:

- Compreender os fundamentos da **Análise Exploratória de Dados (AED)**;
- Explorar e interpretar conjuntos de dados **Iris Flower** utilizando a linguagem **R**;
- Produzir estatísticas descritivas, gráficos exploratórios e relatórios automatizados; e
- Utilizar os pacotes **summarytools** e **DataExplorer** para apoiar a exploração inicial dos dados.



Conteúdo



1. Introdução à Análise Exploratória de Dados

- Conceitos
- Objetivos
- Fluxo de trabalho

2. Análise Exploratória com o conjunto Iris

- Importação e inspeção
- Estatísticas descritivas
- Visualização de dados

3. Automatizando a AED com summarytools

- Tabelas de frequências
- Estatísticas descritivas
- Relatórios automatizados

4. Automatizando a AED com DataExplorer

- Inspeção dos dados
- Valores ausentes
- Variáveis categóricas
- Correlação
- Relatórios automatizados

5. Atividade prática



Módulo 3

Análise Exploratória de Dados

Parte 1

Dataset Iris Flower

Fisher (1936)



AED: O que investigar nos dados?



💡 A AED busca compreender a **estrutura**, a **qualidade** e o **comportamento dos dados**, orientando as etapas seguintes da análise.

Estrutura dos dados

- Quantas observações existem?
- Quais são as variáveis?
- Qual é o tipo de cada variável (numérica, etc.)?

Qualidade dos dados

- Existem valores ausentes?
- Existem valores extremos (outliers)?
- Existem erros ou inconsistências nos dados?

Comportamento dos dados

- Como as variáveis estão distribuídas?
- Quais são suas principais características?
- Existe relação entre as variáveis?
- Existem padrões ou tendências nos dados?



Fluxo de Trabalho da AED



1. Inspeção

Estrutura e tipos de dados



2. Qualidade

Valores ausentes, inconsistências e outliers



3. Exploração

Estatísticas descritivas, distribuições e relações



4. Insights

Interpretação e tomada de decisão



Iris Flower Dataset



O conjunto de dados **Iris Flower** está disponível no **R** (objeto `iris`) e em diversos repositórios públicos, como o **UCI Machine Learning Repository**.

Características do conjunto de dados

- O conjunto de dados foi utilizado por **Ronald A. Fisher** no artigo *The Use of Multiple Measurements in Taxonomic Problems* (1936).
- **150 observações** (flores)
- **3 espécies** (*Setosa*, *Versicolor* e *Virginica*), com **50 observações** de cada espécie
- **5 variáveis**:
 - 4 quantitativas: `Sepal.Length`, `Sepal.Width`, `Petal.Length` e `Petal.Width`
 - 1 qualitativa: `Species`



Iris Flower Dataset



Base de dados das Flores de Íris

Iris flower dataset

Setosa




Tina Monto, CC BY-SA 4.0, via Wikimedia Commons

Versicolor



Charles de Mille-Isles from Mille-Isles, Canada, CC BY 2.0, via Wikimedia Commons

Virginica




Robert H. Mohlenbrock. Courtesy of USDA NRCS, Public domain, via Wikimedia Commons

pt.wikipedia.org

Quais características morfológicas permitem distinguir essas três espécies?

Iris Flower Dataset



Fonte: <https://www.integratedots.com>



Módulo 3 - Análise Exploratória de Dados

Parte 2

AED: Iris Dataset


Usando Tidyverse



Organização do Projeto



Antes de iniciar a AED, organize um projeto (.Rproj):



 iris.csv

Conjunto de dados utilizado na análise. Armazene-o na pasta **data/**.

 01-AED.R

Script onde será desenvolvida toda a análise exploratória.

® Projeto.Rproj

Abra o projeto para utilizar caminhos relativos.



AED: Iris Flower Dataset



Passo 1 (Importação): Importar o arquivo **Iris.csv** armazenado na pasta **data/** do projeto.

```
library(readr)

data <- read_csv(
  file = "data/Iris.csv",
  col_types = "ddddf"
)
```

💡 O argumento `col_types = "ddddf"` define os tipos (classe) das 5 variáveis durante a importação, evitando conversões automáticas.



AED: Iris Flower Dataset



Passo 2 (Inspeção): Verificar a estrutura dos dados e confirmar se a importação foi realizada corretamente.

```
# Dimensão do conjunto de dados  
dim(data)
```

```
# Estrutura das variáveis  
glimpse(data)
```

```
# Nome das variáveis  
names(data)
```

```
# Primeiras observações  
head(data)
```

💡 Essas funções permitem inspecionar rapidamente a estrutura do conjunto de dados.



AED: Iris Flower Dataset



Passo 2 (Inspeção): Qual a estrutura do conjunto de dados?

```
glimpse(data)
```

```
## Rows: 150
## Columns: 5
## $ Sepal_Length <dbl> 5.1, 4.9, 4.7, 4.6, 5.0, 5.4, 4.6, 5.0, 4.4, 4.9, 5.4, 4...
## $ Sepal_Width <dbl> 3.5, 3.0, 3.2, 3.1, 3.6, 3.9, 3.4, 3.4, 2.9, 3.1, 3.7, 3...
## $ Petal_Length <dbl> 1.4, 1.4, 1.3, 1.5, 1.4, 1.7, 1.4, 1.5, 1.4, 1.5, 1.5, 1...
## $ Petal_Width <dbl> 0.2, 0.2, 0.2, 0.2, 0.2, 0.4, 0.3, 0.2, 0.2, 0.1, 0.2, 0...
## $ Species <fct> Iris-setosa, Iris-setosa, Iris-setosa, Iris-setosa, Iris-...
```

Experimente: `str()`, `ncol()`, `nrow()`, `tail()`, `is.na()`, ...



AED: Iris Flower Dataset



Passo 3 (Análise Exploratória): Obter a frequência das categorias da variável **Species**.

```
data |>
  count(Species)
```

```
## # A tibble: 3 × 2
##   Species      n
##   <fct>    <int>
## 1 Iris-setosa      50
## 2 Iris-versicolor  50
## 3 Iris-virginica   50
```

- 💡 O operador `|>` (Piper) envia o conjunto de dados para `count()`.
- 💡 A função `count()` contabiliza as observações por categoria.



AED: Iris Flower Dataset



Passo 3 (Análise Exploratória): Obter a frequência relativa das categorias da variável **Species**.

```
data |>
  count(Species) |>
  mutate(
    Percentual = 100 * n / sum(n)
  )
```

```
## # A tibble: 3 × 3
##   Species          n Percentual
##   <fct>        <int>      <dbl>
## 1 Iris-setosa     50       33.3
## 2 Iris-versicolor 50       33.3
## 3 Iris-virginica  50       33.3
```

💡 A **frequência relativa** representa a proporção de observações em cada categoria.



AED: Iris Flower Dataset



Passo 3 (Análise Exploratória): Obter estatísticas descritivas das variáveis quantitativas.

```
data |>
  summarise(
    across(
      .cols = where(is.numeric),
      .fns = mean,
      .names = "Média_{.col}"
    )
  )
```

```
## # A tibble: 1 × 4
##   Média_Sepal_Length Média_Sepal_Width Média_Petal_Length Média_Petal_Width
##           <dbl>           <dbl>           <dbl>           <dbl>
## 1           5.84           3.05           3.76           1.20
```

💡 `summarise()` resume os dados, e `across()` aplica a mesma operação a múltiplas variáveis.



AED: Iris Flower Dataset



Passo 3 (Análise Exploratória): Obter múltiplas estatísticas descritivas das variáveis quantitativas.

```
data |>
  summarise(
    across(
      .cols = where(is.numeric),
      .fns = list(
        Média = mean,
        DP = sd,
        Mínimo = min,
        Máximo = max
      )
    )
  )
```

💡 `across()` permite aplicar várias funções simultaneamente a múltiplas variáveis.



AED: Iris Flower Dataset



Passo 3 (Análise Exploratória): Obter estatísticas descritivas por espécie.

```
data |>
  group_by(Species) |>
  summarise(
    across(
      .cols = where(is.numeric),
      .fns = mean
    )
  )
```

```
## # A tibble: 3 × 5
##   Species      Sepal_Length Sepal_Width Petal_Length Petal_Width
##   <fct>          <dbl>         <dbl>         <dbl>         <dbl>
## 1 Iris-setosa      5.01           3.42           1.46           0.244
## 2 Iris-versicolor  5.94           2.77           4.26           1.33
## 3 Iris-virginica   6.59           2.97           5.55           2.03
```

💡 `group_by()` agrupa as observações e `summarise()` calcula as estatísticas para cada grupo.




AED: Iris Flower Dataset



Passo 3 (Análise Exploratória): Visualizar a distribuição das observações por espécie.

```
ggplot(  
  data,  
  aes(x = Species)  
) +  
  geom_bar() +  
  labs(  
    x = "Espécie",  
    y = "Frequência"  
  ) +  
  theme_minimal()
```

💡 `geom_bar()` constrói um gráfico de contagem para variáveis categóricas.




AED: Iris Flower Dataset



Passo 3 (Análise Exploratória): Comparar a distribuição de uma variável quantitativa entre as espécies.

```
ggplot(
  data,
  aes(
    x = Species,
    y = Sepal_Length
  )
) +
  geom_boxplot() +
  labs(
    x = "Espécie",
    y = "Comprimento da Sépala (cm)"
  ) +
  theme_minimal()
```

💡 `geom_boxplot()` resume a distribuição dos dados por meio da mediana, quartis e valores extremos.




AED: Iris Flower Dataset



Passo 3 (Análise Exploratória): Comparar as médias e desvios-padrão entre as espécies.

```
data |>
  group_by(Species) |>
  summarise(
    Media = mean(Sepal_Length),
    DP = sd(Sepal_Length)
  ) |>
  ggplot(
    aes(
      x = Species,
      y = Media
    )
  ) +
  geom_col() +
  geom_errorbar(
    aes(
      ymin = Media - DP,
      ymax = Media + DP
    ),
    width = 0.2
  ) +
  labs(
    x = "Espécie",
    y = "Comprimento da Sépala (cm)"
  ) +
  theme_minimal()
```




AED: Iris Flower Dataset



Passo 3 (Análise Exploratória): Avaliar a relação entre duas variáveis quantitativas.

```
ggplot(  
  data,  
  aes(  
    x = Sepal_Length,  
    y = Petal_Length,  
    color = Species  
  )  
) +  
  geom_point(  
    size = 2  
  ) +  
  labs(  
    x = "Comprimento da Sépala (cm)",  
    y = "Comprimento da Pétala (cm)",  
    color = "Espécie"  
  ) +  
  theme_minimal()
```

💡 `geom_point()` representa a relação entre duas variáveis quantitativas.



Parte 3

Automatização da AED

Pacote: summarytools



Pacote summarytools



O pacote **summarytools** reúne funções para produzir, de forma rápida, tabelas e resumos estatísticos.

Principais funcionalidades

-  Tabelas de frequências para variáveis categóricas.
-  Estatísticas descritivas para variáveis numéricas.
-  Resumos completos de conjuntos de dados.
-  Relatórios formatados para HTML, Markdown e outros formatos.

Autor: Dominic Comtois

Vignette: `vignette("introduction", package = "summarytools")`



AED Automatizada: Pacote summarytools



Tabela de frequências utilizando a função `freq()`.

```
library(summarytools)

data |>
  freq(
    var = Species,
    report.nas = FALSE,
    style = "rmarkdown",
    heading = FALSE
  )
```

💡 `freq()` produz uma tabela de frequências absoluta, relativa e acumulada.

	Freq	%	% Cum.
Iris-setosa	50	33.33	33.33
Iris-versicolor	50	33.33	66.67
Iris-virginica	50	33.33	100.00
Total	150	100.00	100.00



AED Automatizada: Pacote summarytools



Estatísticas descritivas utilizando a função `descr()`.

```
library(summarytools)

data |>
  descr(
    style = "rmarkdown",
    heading = FALSE
  )
```

💡 `descr()` produz um resumo estatístico das variáveis numéricas do conjunto de dados.



Resumo estatístico

Média

Mediana

Desvio-padrão

Quartis

Mínimo

Máximo

...



AED Automatizada: Pacote summarytools



Resultado produzido pela função `descr()`.

	Petal_Length	Petal_Width	Sepal_Length	Sepal_Width
Mean	3.76	1.20	5.84	3.05
Std.Dev	1.76	0.76	0.83	0.43
Min	1.00	0.10	4.30	2.00
Q1	1.60	0.30	5.10	2.80
Median	4.35	1.30	5.80	3.00
Q3	5.10	1.80	6.40	3.30
Max	6.90	2.50	7.90	4.40
MAD	1.85	1.04	1.04	0.37
IQR	3.50	1.50	1.30	0.50
CV	0.47	0.64	0.14	0.14
Skewness	-0.27	-0.10	0.31	0.33
SE.Skewness	0.20	0.20	0.20	0.20
Kurtosis	-1.42	-1.36	-0.61	0.20
N.Valid	150.00	150.00	150.00	150.00
N	150.00	150.00	150.00	150.00
Pct.Valid	100.00	100.00	100.00	100.00



AED Automatizada: Pacote summarytools



A função `descr()` também permite selecionar quais estatísticas serão apresentadas.

```
library(summarytools)

data |>
  descr(
    stats = c(
      "mean",
      "sd",
      "min",
      "max"
    ),
    style = "rmarkdown",
    heading = FALSE
  )
```

	Petal_Length	Petal_Width	Sepal_Length	Sepal_Width
Mean	3.76	1.20	5.84	3.05
Std.Dev	1.76	0.76	0.83	0.43
Min	1.00	0.10	4.30	2.00
Max	6.90	2.50	7.90	4.40

Estatísticas disponíveis: "mean", "median", "sd", "var", "min", "max", "range", "iqr", "cv", "skewness", "kurtosis", "n.valid", "n.miss", ...

💡 Utilize o argumento `stats` para definir quais estatísticas descritivas



AED Automatizada: Pacote summarytools



A função `dfSummary()` produz um relatório completo do conjunto de dados.

```
library(summarytools)

data |>
  dfSummary(
    style = "grid",
    headings = FALSE
  ) |>
  view()
```

💡 `dfSummary()` reúne, em um único relatório, informações sobre todas as variáveis do conjunto de dados.

 **Variáveis**



 **Classe**

 **Estatísticas**

 **Valores ausentes**

 **Distribuição**

 **Valores distintos**

...



AED Automatizada: Pacote **summarytools**



A função `stby()` aplica uma função do **summarytools** separadamente para cada grupo de uma variável categórica.

```
library(summarytools)

stby(
  data = data,
  INDICES = data$Species,
  FUN = descr,
  style = "rmarkdown",
  headings = FALSE
)
```

💡 `stby()` executa a função `descr()` para cada espécie do conjunto de dados.



Módulo 3 - Análise Exploratória de Dados

Parte 3

Automatização da AED

Pacote: DataExplorer



Pacote DataExplorer



O pacote **DataExplorer** reúne funções para **automatizar** diversas etapas da **Análise Exploratória de Dados (AED)**, permitindo explorar rapidamente a estrutura, a qualidade e o comportamento dos dados.

Poucas linhas de código → Tabelas, gráficos e relatórios exploratórios

Principais recursos

- Resumo geral dos dados
- Detecção de valores ausentes
- Gráficos: Histogramas e densidade

Também permite

- Análise de correlação
- Identificação de padrões
- Análise de componentes principais
- Relatório HTML completo



Instalando e carregando o pacote



```
install.packages("DataExplorer")  
library(DataExplorer)
```

Após carregar o pacote, suas funções estarão disponíveis para automatizar diferentes etapas da **Análise Exploratória de Dados (AED)**.

💡 O pacote é compatível com objetos da classe **data.frame** e **tibble**, integrando-se facilmente ao fluxo de trabalho do **Tidyverse**.



Conhecendo o conjunto de dados



- **Inspeção dos dados:** utilize a função **introduce()** para obter um resumo geral do conjunto de dados.

```
introduce(data)
```




Conhecendo o conjunto de dados



💡 A função `plot_intro()` apresenta, em um único painel, informações sobre observações, variáveis, tipos de dados e valores ausentes.

```
plot_intro(data)
```



Identificando valores ausentes



- A função `plot_missing()` resume visualmente os **valores ausentes** de cada variável.

```
data |>
  mutate(
    Sepal_Length = replace(Sepal_Length, c(5, 18, 42), NA),
    Species = replace(Species, c(10, 35), NA)
  ) |>
  plot_missing()
```

💡 Valores ausentes foram inseridos artificialmente para ilustrar a função.




Identificando valores ausentes



🔍 O que observar?

- Existem muitas observações com **valores ausentes**?
- **Quais variáveis** são mais afetadas?
- É necessário **tratar os valores ausentes** antes da análise?



Distribuição das variáveis categóricas



A função **plot_bar()** produz gráficos de barras para as **variáveis categóricas**.

```
data |>  
  plot_bar()
```

💡 Um gráfico é gerado para cada **variável categórica** do conjunto de dados.




Distribuição das variáveis categóricas



O que observar?

- As classes estão **balanceadas**?
- Existem **categorias raras**?
- Há possíveis **inconsistências** nas categorias?



Correlação entre variáveis



- A função **plot_correlation()** calcula e representa graficamente a **correlação** entre as variáveis numéricas.

```
data |>
  select(where(is.numeric)) |>
  plot_correlation()
```

💡 Produz um **mapa de calor** (heatmap) da **correlação de Pearson** entre as variáveis numéricas.



Correlação entre variáveis




🔍 O que observar?

- Existem variáveis com **forte associação linear**?
- As associações são **positivas** ou **negativas**?
- Quais pares apresentam os **maiores coeficientes de correlação**?

📌 Lembrar (Pearson)

- O sinal (+ ou -) indica a direção da associação linear.
- O valor absoluto de r ($|r|$) indica a força da associação linear.
- Quanto mais próximo de ± 1 , mais forte é a associação linear.
- A significância estatística da correlação pode ser avaliada pelo teste t .



Correlação $\neq$ Causalidade



- A correlação mede a **intensidade e a direção** associação linear, não a relação de **causa e efeito**.

Associação $\neq$ Causa e efeito

Correlação

- As variáveis **variam juntas**.
- Pode ser **positiva** ou **negativa**.
- Não explica **por que** isso acontece.

Causalidade

- Alterações em uma variável **provocam mudanças** na outra.
- Requer evidências adicionais, como experimentos ou estudos bem controlados.



Correlação $\neq$ Causalidade



Exemplo: conjunto Iris

As variáveis **Petal.Length** e **Petal.Width** apresentam forte correlação positiva (0,96).

Pergunta

O aumento do **comprimento da pétala** causa o aumento da **largura da pétala**?

✗ Não necessariamente!

💡 A forte correlação provavelmente decorre do fato de que ambas as variáveis são influenciadas por **fatores biológicos comuns**, e não porque uma variável causa alterações na outra.



Relatório exploratório automatizado



- A função **create_report()** gera automaticamente um **relatório HTML** contendo diversas análises exploratórias do conjunto de dados.

```
data |>
  create_report(output_file = "Relatorio.html",
               output_dir = "report")
```

💡 O relatório reúne tabelas, gráficos e estatísticas em um único documento, facilitando a inspeção inicial dos dados.



Atividade Prática



- Cada grupo (até 4 pessoas) deverá criar um Projeto (.Rproj) e desenvolver uma AED. Inicialmente, explore os pacotes estudados do **Tidyverse** (**readr**, **dplyr**, **ggplot2**, etc.). Além disso, explore outras bibliotecas especializadas em AED, como os Pacotes **summarytools**, **DataExplorer**, **GGally**, **SmartEDA**, **psych**.

As bases de dados são as seguintes:

- **Grupo 1: HCV Doador de Sangue** - (contém valores laboratoriais de doadores de sangue e pacientes com hepatite C e valores demográficos como idade.)
- **Grupo 2: Vertebral Column** - (6 características biomecânicas usadas para classificar pacientes ortopédicos em 3 classes (normal, hérnia de disco ou espondilolistese) ou 2 classes (normal ou anormal))
- **Grupo 3: Wine** - (Usando a análise química determinar a origem dos vinhos)
- **Grupo 4: Seeds** - (Medidas de propriedades geométricas de grãos pertencentes a três diferentes variedades de trigo.)
- **Grupo 5: Car Evaluation** - (Dados de avaliação de carros baseado em 6 atributos)
- **Grupo 6: Pinguins** - (Medidas de pinguins adultos perto da Estação Palmer, Antártida (Palmer Station))
(dados::penguins)



Boas práticas em AED



💡 A qualidade de uma **Análise Exploratória de Dados (AED)** depende tanto das ferramentas utilizadas quanto da **interpretação crítica** dos resultados.

- ✓ **Conheça seus dados** antes de construir modelos e usar técnicas multivariadas.
- ✓ **Combine tabelas e gráficos** para compreender os dados.
- ✓ **Investigue valores ausentes** e possíveis inconsistências.
- ✓ **Correlação indica associação**, não relação de causa e efeito.
- ✓ **Ferramentas automatizam análises. A interpretação continua sendo responsabilidade do analista.**

🎯 **Uma boa AED produz conhecimento para orientar as próximas etapas da análise.**



Obrigado!



@lmftca_ufpa



<https://www.lmftca.com.br/>

